



UNIVERSIDAD DE SEVILLA
ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA
INFORMÁTICA

Deep Learning en Grafos para la Detección de Patrones en Redes Financieras.

Asignatura: TSCD

Pedro Escudero Murcia

Enero 2026

Índice

1. Introducción	2
2. Marco Teórico	3
2.1. Codificación Estructural y Limitaciones de las GNN	4
2.2. Redes Neuronales Convolucionales en Grafos (GCN)	4
3. Metodología	5
3.1. Creación del Dataset e Ingeniería de Características	6
3.2. Análisis Exploratorio y Definición de Hiperparámetros	7
3.3. Estrategia de Entrenamiento y Preprocesamiento	8
3.4. Arquitectura de la Red Neuronal Convolutional (GCN)	9
3.5. Protocolo de Evaluación y Análisis del Espacio Latente	10
3.6. Reproducibilidad y Entorno Computacional	11
4. Resultados y Discusión	11
4.1. Caracterización Topológica de los Regímenes (Análisis del Input)	12
4.2. Desempeño del Clasificador y Análisis de Errores	13
4.3. Interpretabilidad y Espacio Latente (Análisis de Embeddings)	14
4.4. Discusión General: La GCN como Herramienta de Auditoría	16
5. Conclusiones	17

1. Introducción

El estudio de los sistemas económicos a menudo nos enfrenta a comportamientos complejos cuya descripción va más allá de las aproximaciones lineales tradicionales. Este trabajo se adentra precisamente en ese terreno, el de la economía computacional y la inteligencia artificial, con un interés particular en la detección de patrones estructurales dentro del riesgo sistémico. A lo largo de este capítulo introductorio, presentaremos los conceptos fundamentales para comprender estos sistemas, describiremos las herramientas de simulación utilizadas y definiremos el problema central: cómo las regulaciones financieras alteran la topología de las redes interbancarias de una manera que puede ser detectada mediante Aprendizaje Profundo (*Deep Learning*).

Para empezar, es útil definir el contexto metodológico. Comprender la estabilidad financiera requiere herramientas que superen las limitaciones de los modelos econométricos clásicos, los cuales suelen asumir agentes homogéneos y dinámicas de equilibrio simples. En este sentido, los Modelos Basados en Agentes (ABM) [5] funcionan como "laboratorios", permitiéndonos simular interacciones a microescala para observar los fenómenos macroscópicos que emergen de ellas. Este enfoque es fundamental cuando, como ocurre en el ámbito bancario, la escasez de datos privados impide realizar experimentos directos en el mundo real.

Este trabajo no parte de cero, sino que se plantea como una extensión directa de una replicación previa del modelo CRISIS, originalmente propuesto por Poledna et al. [8]. En esa etapa anterior, el reto consistió en calibrar un simulador funcional capaz de reproducir la dinámica financiera pese a la sensibilidad del sistema a las condiciones iniciales. Ahora, con esa herramienta validada, utilizamos el modelo para generar datos sintéticos bajo tres regímenes regulatorios distintos: un escenario base de libre mercado, la aplicación de una Tasa Tobin (que grava indiscriminadamente el volumen de transacciones) y la implementación de un Impuesto al Riesgo Sistémico (SRT), diseñado para penalizar específicamente las operaciones que aumentan la vulnerabilidad de la red.

El funcionamiento del simulador se basa en un ciclo iterativo (**Figura 1**) donde los agentes; hogares, empresas y bancos, interactúan en diversos mercados. Sin embargo, no toda la información generada tiene el mismo valor para nuestro análisis. En los mercados de bienes y de crédito a empresas, las interacciones suelen estar dominadas por procesos de búsqueda aleatoria e información imperfecta, lo que introduce un nivel de ruido estocástico que dificulta la identificación de patrones claros. Por el contrario, el mercado interbancario, donde las entidades gestionan sus necesidades de liquidez, responde a reglas de solvencia más estrictas y deterministas. Por esta razón, nuestra metodología filtra el ruido de la economía real para centrarse exclusivamente en la topología de la red interbancaria, considerándola el sustrato físico donde las regulaciones dejan su huella más profunda.

El objetivo central de esta investigación es determinar si es posible entrenar un modelo de inteligencia artificial para que distinga qué regulación está activa observando únicamente la estructura de la red financiera. La hipótesis de partida sugiere que la Tasa Tobin y el SRT tienen efectos cualitativamente distintos: mientras que la primera actúa como una fricción que reduce el volumen global del mercado sin alterar necesariamente su forma, el SRT ejerce una presión selectiva que fuerza una reorganización de los enlaces entre bancos. Para verificar esto, empleamos Redes Neuronales Convolucionales en Grafos (GCN), una

técnica de Aprendizaje Profundo topológico capaz de procesar la matriz de adyacencia y los atributos de los nodos simultáneamente.

Habiendo introducido el problema y el sistema físico-económico bajo estudio, el resto del trabajo se organizará para validar esta hipótesis experimentalmente. Se detallará cómo el diseño de la red neuronal permite clasificar los regímenes fiscales y se discutirán los resultados obtenidos, buscando demostrar que las intervenciones políticas no solo afectan a las variables macroeconómicas, sino que reconfiguran la arquitectura misma del sistema financiero de una forma predecible y detectable.



Figura 1: Representación esquemática de la simulación de agentes.

2. Marco Teórico

Una vez descritos los mecanismos de generación de datos sintéticos a través del Modelo Basado en Agentes, resulta imprescindible establecer el formalismo matemático que nos permitirá procesar y clasificar las estructuras resultantes. En esta sección, nos alejamos de

la lógica puramente transaccional de los mercados para adoptar una perspectiva topológica [6]. El objetivo es tender un puente entre la Teoría de Grafos clásica y el Aprendizaje Profundo Geométrico [3].

2.1. Codificación Estructural y Limitaciones de las GNN

Para modelizar el sistema interbancario, comenzamos definiendo formalmente el grafo como una estructura $G = (V, E)$, donde V representa el conjunto de bancos y E las relaciones financieras o exposiciones entre ellos, descritas por una matriz de adyacencia A [6]. Si bien las Redes Neuronales en Grafos (GNN) son herramientas excepcionales para tratar este tipo de datos no euclidianos, no son infalibles. Su diseño se basa en el paso de mensajes entre vecinos inmediatos, lo que genera una limitación intrínseca conocida como "miopía local": la red tiende a ignorar patrones globales complejos que no son evidentes observando únicamente el vecindario directo de un nodo. Para subsanar esta carencia, nuestra metodología enriquece el vector de características de cada banco incorporando métricas de centralidad precalculadas, las cuales actúan como una codificación estructural que guía al modelo hacia las propiedades críticas de la red.

La primera de estas limitaciones es la dificultad para identificar nodos que, aunque no tengan muchas conexiones directas, son vitales para mantener unida la red. Imaginemos un banco pequeño que actúa como único puente entre dos grandes comunidades financieras; una GNN estándar podría subestimar su importancia. Para corregirlo, incorporamos la **Centralidad de Intermediación** (*Betweenness Centrality*). Esta métrica cuantifica la frecuencia con la que un nodo forma parte del camino más corto entre otros dos, señalando explícitamente aquellos puntos que actúan como cuellos de botella o conductos críticos para el contagio financiero.

De igual forma, el proceso de difusión de información en una GNN es finito (limitado por el número de capas), mientras que la influencia real en un sistema económico es un fenómeno de largo alcance que tiende a un estado estacionario. Para capturar esta influencia asintótica, utilizamos la **Centralidad de Autovector** (*Eigenvector Centrality*). Matemáticamente asociada al autovector principal de la matriz de adyacencia, esta métrica asigna importancia a un nodo no solo por cuántos vecinos tiene, sino por la calidad e influencia de esos vecinos. Al incluirla, proporcionamos a la red neuronal una medida del prestigio o poder real de cada banco en el equilibrio a largo plazo.

Por último, para dotar al modelo de una noción sobre la robustez local del sistema, integramos el **Coefficiente de Agrupamiento** (*Clustering Coefficient*) [6]. Las GNN básicas tienen dificultades teóricas para detectar subestructuras cerradas como triángulos, que en términos financieros representan redundancia y estabilidad. Este coeficiente mide la probabilidad de que los socios comerciales de un banco también operen entre sí, revelando la cohesión del tejido interbancario y su capacidad para resistir fallos locales sin desmoronarse.

2.2. Redes Neuronales Convolucionales en Grafos (GCN)

Con la representación de los nodos enriquecida mediante estas métricas, empleamos Redes Neuronales Convolucionales en Grafos (GCN) para abordar el problema de clasificación. A diferencia de las redes convolucionales clásicas que procesan imágenes (donde los píxeles forman una cuadrícula perfecta), las GCN deben operar sobre la estructura irregular de

las conexiones bancarias. Para ello, seguimos la arquitectura espectral propuesta por Kipf y Welling [7, 2], la cual ofrece un balance idóneo entre potencia expresiva y eficiencia computacional.

La intuición física detrás de este modelo es la de un proceso de difusión. En lugar de realizar operaciones complejas en el dominio de Fourier, el modelo aproxima la convolución mediante un esquema de "paso de mensajes". En cada capa de la red, cada banco actualiza su estado interno agregando la información de sus vecinos y mezclándola con la suya propia. La regla de actualización para el estado h_i de un nodo i en la capa $l + 1$ se puede expresar como:

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}(i) \cup \{i\}} \frac{1}{\sqrt{\deg(i) \deg(j)}} W^{(l)} h_j^{(l)} \right) \quad (1)$$

Un detalle crucial en esta ecuación es el término de normalización $\frac{1}{\sqrt{\deg(i) \deg(j)}}$. En las redes financieras, que suelen tener una estructura libre de escala con unos pocos bancos masivos (hubs) y muchos pequeños, la información de los grandes nodos podría inundar el sistema, desestabilizando el aprendizaje. Esta normalización corrige ese efecto, asegurando que la contribución de cada vecino se pondere adecuadamente según la conectividad de ambas partes.

Desde un punto de vista matricial, que es como se implementa computacionalmente para ganar eficiencia, esta propagación se resume en una operación elegante utilizando el truco de renormalización. Si definimos $\tilde{A}$ como la matriz de adyacencia con autoconexiones y $\tilde{D}$ como su matriz de grados [7], la evolución de toda la red de una capa a la siguiente viene dada por:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (2)$$

Aquí, $W^{(l)}$ contiene los pesos que la red ajustará durante el entrenamiento para aprender a distinguir los patrones. La arquitectura final se define por su profundidad (cuántos saltos de distancia recorre la información) y su anchura (la complejidad de las características extraídas). Finalmente, tras procesar la información a nivel de nodo, aplicamos una operación de *Global Mean Pooling* que promedia los estados de todos los bancos. Esto condensa toda la complejidad de la red en un único vector latente [2], una "huella digital" del sistema completo que permite al clasificador determinar si la topología observada corresponde a un mercado libre, a una Tasa Tobin o a un Impuesto al Riesgo Sistémico.

3. Metodología

La validación de las hipótesis de este trabajo requiere un diseño experimental que adapte la complejidad del sistema financiero simulado a las necesidades de la Inteligencia Artificial. Existe una fricción fundamental en la naturaleza de los datos: mientras que el Modelo Basado en Agentes (ABM) genera un flujo continuo y cambiante de transacciones, los modelos de GCN necesitan trabajar con estructuras fijas y discretas. Por tanto, nuestra metodología no consiste solo en recolectar datos, sino en transformarlos. El objetivo es

filtrar el ruido temporal de la simulación para aislar la estructura de red estable que, según nuestra teoría, define a cada tipo de regulación. A continuación, explicamos el procedimiento para convertir los datos crudos del ABM en grafos procesables y detallamos la ingeniería de características necesaria para que el modelo capture fielmente el estado del sistema.

3.1. Creación del Dataset e Ingeniería de Características

El primer desafío metodológico consiste en traducir la dinámica temporal continua del Modelo Basado en Agentes (ABM) a una representación estática y discreta asimilable por los algoritmos de Aprendizaje Profundo Geométrico. Las simulaciones generan archivos de registro (*parquet*) que documentan la evolución paso a paso de cada entidad y transacción. Sin embargo, dado que nuestro objetivo es clasificar regímenes regulatorios basándonos en su huella estructural y no en transitorios de corto plazo, aplicamos una estrategia de agregación temporal.

El procedimiento de ingestión de datos procesa dos fuentes primarias por simulación: el registro de estados financieros de los bancos y el registro de la red interbancaria. Para eliminar el ruido estocástico inherente a las fluctuaciones diarias del mercado, colapsamos la dimensión temporal calculando el promedio global de las variables de estado para cada banco i durante todo el periodo de simulación T . De esta forma, obtenemos un perfil estacionario definido por la liquidez media, el patrimonio medio y el nivel medio de *DebtRank*. Paralelamente, condensamos la red de transacciones promediando los pesos de los enlaces dirigidos entre cada par de nodos origen-destino, construyendo así una matriz de adyacencia ponderada que refleja la estructura persistente de las exposiciones interbancarias.

Una vez obtenida esta imagen promedio del sistema, instanciamos un grafo dirigido $G = (V, E)$ utilizando la librería NetworkX [2]. Es crucial destacar que en este paso se fuerzan explícitamente la inclusión de todos los nodos presentes en el registro bancario, garantizando que las entidades aisladas (aquellas que no participan en el mercado interbancario bajo ciertas regulaciones) sean parte del grafo y no desaparezcan del análisis, ya que su aislamiento es en sí mismo una señal regulatoria relevante.

Con la topología reconstruida, procedemos a la ingeniería de características. Para superar la ya mencionada "miopía local" de las Redes Neuronales en Grafos (GNN), enriquecemos el vector de características de cada nodo con métricas topológicas calculadas *a priori*. A las tres variables financieras endógenas (Liquidez, Patrimonio, *DebtRank*) añadimos tres descriptores estructurales exógenos:

- **Coefficiente de Clustering:** Para capturar la robustez local y la formación de comunidades.
- **Centralidad de Intermediación (*Betweenness*):** Para identificar nodos puente críticos en el flujo de contagio.
- **Centralidad de Autovector (*Eigenvector*):** Para ponderar la influencia de un banco en función de la importancia de sus vecinos.

El resultado es una matriz de características $X \in \mathbb{R}^{N \times 6}$, donde N es el número de bancos. Finalmente, esta estructura matemática se convierte en tensores compatibles con *PyTorch Geometric*, encapsulando la matriz de características X , el índice de conexiones

(en formato COO) y los pesos de las aristas en un objeto `Data`. Cada grafo es etiquetado numéricamente según el escenario regulatorio que lo generó (0 para Mercado Libre, 1 para Tasa Tobin y 2 para Impuesto al Riesgo Sistémico), completando así la construcción de un dataset supervisado listo para el entrenamiento.




Figura 2: Diagrama esquemático del flujo de procesamiento de datos

3.2. Análisis Exploratorio y Definición de Hiperparámetros

Antes de proceder al entrenamiento de la red neuronal, resulta imperativo realizar una inspección estadística y topológica de los datos generados. Este paso no es meramente descriptivo, sino que cumple una función de calibración arquitectónica: las propiedades geométricas de los grafos dictarán las dimensiones físicas (profundidad y anchura) del modelo GCN.

Para validar la separabilidad de las clases y la calidad de la señal en nuestros datos, seleccionamos dos métricas representativas para un análisis de distribución detallado, descartando una revisión exhaustiva de todas las variables para focalizarnos en los ejes teóricos del problema:

- **Centralidad de Intermediación (*Betweenness Centrality*):** Seleccionamos esta métrica topológica porque actúa como el indicador principal de la estructura de "hubs.º nodos puente. Metodológicamente, su estudio es crucial para verificar si las regulaciones, especialmente el SRT, logran su objetivo físico de descentralizar la red, alterando las colas de la distribución de conectividad.
- **DebtRank:** Elegimos esta variable como contraparte financiera. Al ser una medida directa del impacto sistémico potencial (riesgo de contagio), su análisis comparativo frente al *Betweenness* nos permite discernir si las intervenciones políticas afectan únicamente a los balances contables o si, efectivamente, reconfiguran la arquitectura del sistema.

Complementariamente, evaluamos la redundancia de información mediante una matriz de correlación de Spearman. El objetivo es detectar colinealidad no lineal entre las variables de estado financiero (como el Patrimonio) y las métricas de centralidad calculadas (como el *Eigenvector*). Una alta correlación implicaría que la topología es un mero reflejo de los

estados financieros, mientras que una baja correlación justificaría el uso de GNNs para capturar información estructural latente no evidente en los balances.

Para determinar la anchura de la red (número de canales ocultos), aplicamos un Análisis de Componentes Principales (PCA) [3] sobre los vectores promedio de los grafos. La varianza explicada por los primeros componentes principales funciona como una heurística para dimensionar la complejidad del espacio latente: una alta varianza acumulada sugiere que los datos residen en una variedad de baja dimensión, permitiendo arquitecturas más estrechas, mientras que una dispersión mayor requeriría vectores de características más amplios.

Finalmente, el diseño de la profundidad de la red (número de capas convolucionales) se fundamenta estrictamente en la estructura física de la red interbancaria. Dado que el mecanismo de paso de mensajes de una GCN propaga información un salto por capa, calculamos el diámetro efectivo de la Componente Conexa Más Grande (LCC) de nuestros grafos. Este valor métrico establece el límite teórico del campo receptivo necesario; metodológicamente, fijamos el número de capas L para que sea proporcional al radio medio de la red, asegurando así que cada nodo pueda integrar información de su vecindario relevante sin incurrir en costes computacionales innecesarios ni en el fenómeno de *over-smoothing* [7].

3.3. Estrategia de Entrenamiento y Preprocesamiento

La transición del análisis exploratorio al aprendizaje supervisado requiere un protocolo riguroso de preparación de datos para garantizar que el modelo aprenda patrones generalizables y no meras particularidades del conjunto de datos. Nuestra metodología de entrenamiento se fundamenta en tres pilares: una división estratificada, una estandarización estricta para evitar fugas de información y un régimen de optimización basado en mini-lotes (*mini-batches*).

Para la partición del dataset, empleamos una estrategia de muestreo aleatorio estratificado (*Stratified Shuffle Split*) [4]. Dividimos el total de grafos generados en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %). A diferencia de una división aleatoria simple, la estratificación fuerza que la proporción de simulaciones correspondiente a cada régimen regulatorio (Mercado Libre, Tasa Tobin, SRT) se mantenga idéntica en ambos subconjuntos. Esta decisión metodológica es crítica para prevenir sesgos de evaluación, asegurando que el modelo sea testado frente a una representación equilibrada de todos los escenarios y no favorezca a las clases mayoritarias por puro azar estadístico.

Posteriormente, abordamos el problema de la heterogeneidad de escalas. Nuestras variables de entrada conviven en rangos numéricos dispares: mientras que las métricas de centralidad como el *Betweenness* oscilan entre 0 y 1, variables financieras como el Patrimonio pueden alcanzar magnitudes de miles o millones. Para facilitar la convergencia del descenso de gradiente, aplicamos una estandarización Z-score a todas las características, transformándolas para que tengan media 0 y varianza 1. Es fundamental destacar el protocolo *anti-leakage* (anti-fuga) aplicado: los parámetros de normalización (μ y σ) se calculan *exclusivamente* utilizando los nodos del conjunto de entrenamiento. Estos parámetros congelados se utilizan luego para transformar el conjunto de prueba. De haber normalizado el dataset completo antes de la división, habríamos contaminado el entrenamiento con información estadística del test, invalidando la evaluación de su capacidad de

generalización.

Finalmente, el flujo de entrenamiento se gestiona mediante *DataLoaders* que agrupan los grafos en mini-lotes (*batches*) de tamaño 128. Optamos por este enfoque de *Mini-Batch Gradient Descent* en lugar del procesamiento por lotes completos (*Full Batch*) o estocástico puro. Metodológicamente, los mini-lotes ofrecen el equilibrio óptimo: proporcionan una estimación del gradiente lo suficientemente estable para converger suavemente, a la vez que introducen el ruido estocástico necesario para escapar de mínimos locales y permiten una gestión eficiente de la memoria de la GPU al no requerir cargar miles de grafos simultáneamente. Durante la fase de entrenamiento, estos lotes se barajan (*shuffling*) en cada época para romper posibles ciclos o correlaciones espurias en el orden de los datos [1].

3.4. Arquitectura de la Red Neuronal Convolutiva (GCN)

El núcleo de nuestro sistema de clasificación es una Red Neuronal Convolutiva en Grafos (GCN) basada en la formulación espectral de Kipf y Welling. A diferencia de las arquitecturas planas o de ancho constante, hemos diseñado una topología tipo *Encoder*, orientada específicamente a la extracción y destilación de características estructurales complejas. Como se ilustra en la **Figura 3**, el flujo de información atraviesa cinco capas convolucionales secuenciales antes de ser condensado en una predicción.

La elección de una profundidad de cinco capas ($L = 5$) no es arbitraria, sino que responde directamente al análisis estructural previo. Dado que cada capa convolutiva propaga información a los vecinos inmediatos (1-hop), una red de cinco capas tiene un campo receptivo efectivo de cinco saltos. Este alcance es suficiente para cubrir el radio medio de la componente conexa principal de nuestros grafos interbancarios, permitiendo que la representación de un nodo integre información de su vecindario extendido sin incurrir en el problema de *over-smoothing* (donde las representaciones de los nodos se vuelven indistinguibles si L es excesivo).

En cuanto a la dimensión de los canales ocultos, la red opera en tres fases diferenciadas:

1. **Expansión (Input $\rightarrow$ 64 canales):** La primera capa proyecta el vector de características original de 6 dimensiones (financieras + topológicas) a un espacio latente de 64 dimensiones. Esta expansión es crítica para permitir que el modelo desempaquete las correlaciones no lineales entre las variables de entrada.
2. **Procesamiento Profundo (64 $\rightarrow$ 64 $\rightarrow$ 32 canales):** Las capas intermedias mantienen y luego reducen gradualmente la dimensionalidad. Aquí, la red refina las características aprendidas, filtrando el ruido y combinando patrones locales en estructuras de orden superior.
3. **Compresión (32 $\rightarrow$ 16 canales):** La última capa convolutiva actúa como un "cuello de botella". Forzamos a la red a comprimir toda la información procesada en un vector de solo 16 dimensiones. Metodológicamente, esto obliga al modelo a descartar redundancias y retener únicamente las características más discriminantes, generando una huella digital compacta del estado de la red.

Para garantizar la robustez del aprendizaje, aplicamos dos mecanismos de control tras cada operación de convolución. Primero, una función de activación no lineal *ReLU* (Rectified Linear Unit) para introducir la capacidad de aproximar funciones complejas. Se-

gundo, una capa de *Dropout* con probabilidad $p = 0,5$ durante la fase de entrenamiento. Este mecanismo apaga aleatoriamente la mitad de las neuronas en cada paso, impidiendo la co-adaptación de características y forzando a la red a desarrollar caminos redundantes para la clasificación, lo cual mejora significativamente la generalización frente a datos no vistos.

Finalmente, para obtener una clasificación a nivel de grafo completo (y no a nivel de nodo), aplicamos una operación de *Global Mean Pooling* sobre los vectores de 16 dimensiones de todos los nodos. Esto genera un único vector invariante al tamaño de la red que sintetiza el estado global del sistema financiero. Este vector se introduce en una capa lineal densa (el clasificador final) que emite los *logits* correspondientes a las tres clases objetivo: Mercado Libre, Tasa Tobin y SRT.




Figura 3: Arquitectura de la GCN propuesta.

3.5. Protocolo de Evaluación y Análisis del Espacio Latente

La validación final del modelo trasciende la mera métrica de aciertos; requiere una auditoría exhaustiva de cómo la red neuronal estructura su conocimiento. Para ello, sometemos al modelo entrenado a un conjunto de pruebas independiente (el 20 % reservado previamente), asegurando que la evaluación se realice sobre grafos que la red nunca ha visto durante el ajuste de pesos. Nuestro esquema de evaluación se divide en tres niveles de profundidad: rendimiento clasificatorio, diagnóstico de errores y calidad de la representación vectorial.

En primer lugar, evaluamos la eficacia predictiva mediante métricas estándar de clasificación. Calculamos la Exactitud Global (Accuracy) como línea base de rendimiento. Sin embargo, dada la sutileza de los efectos regulatorios, la exactitud puede enmascarar ses-

gos hacia clases mayoritarias o fáciles. Por tanto, desglosamos el rendimiento mediante un Informe de Clasificación, analizando la Precisión y la Sensibilidad (Recall) por separado para cada régimen (Mercado Libre, Tasa Tobin, SRT). Esto nos permite detectar si el modelo es consistentemente robusto o si, por el contrario, confunde selectivamente ciertas intervenciones (por ejemplo, si la Tasa Tobin es indistinguible del Mercado Libre desde una perspectiva topológica).

Como herramienta de diagnóstico visual, construimos la *Matriz de Confusión*. Este mapa de calor C_{ij} nos revela no solo cuánto se equivoca el modelo, sino cómo se equivoca. Un análisis de los elementos fuera de la diagonal principal es crítico para interpretar la distancia fenomenológica entre regulaciones: una alta confusión entre dos clases sugeriría que sus huellas estructurales son isomorfos a ojos de la GCN, lo cual tendría profundas implicaciones teóricas sobre la redundancia de dichas políticas.

Finalmente, profundizamos en la caja negra del modelo analizando el Espacio Latente (*Embeddings*). En lugar de observar solo la predicción final, extraemos los vectores de características de 16 dimensiones generados por la capa de *Global Mean Pooling* justo antes de la clasificación. Estos vectores representan la comprensión interna que la red tiene de cada sistema financiero. Para visualizar esta variedad de alta dimensión, empleamos *t-SNE* (*t-Distributed Stochastic Neighbor Embedding*), una técnica de reducción de dimensionalidad no lineal que proyecta los embeddings a un plano 2D preservando la estructura de vecindad local.

Para cuantificar objetivamente la calidad de esta proyección, calculamos el *Silhouette Score*. Esta métrica, acotada entre -1 y 1, mide la cohesión intra-clase y la separación inter-clase de los clusters formados en el espacio latente. Un coeficiente alto validaría nuestra hipótesis central: demostraría que la GNN no solo memoriza etiquetas, sino que ha aprendido a mapear las regulaciones financieras a regiones topológicas distintas y bien definidas dentro del espacio de configuraciones posibles de la red interbancaria.

3.6. Reproducibilidad y Entorno Computacional

Con el objetivo de garantizar la transparencia científica y permitir la replicación independiente de los hallazgos presentados, la totalidad del código fuente desarrollado para este trabajo (incluyendo la implementación del Modelo Basado en Agentes y la arquitectura de la GCN) se encuentra disponible públicamente en el repositorio: <https://github.com/f92esmup/systemic-risk-tax-abm.git>.

La ejecución integral del flujo experimental, que abarca desde la generación de datos sintéticos masivos hasta el entrenamiento y evaluación de la red neuronal, se llevó a cabo en la plataforma en la nube *Google Colab*. Para gestionar la carga computacional inherente a las operaciones tensoriales del Aprendizaje Profundo y el procesamiento de grafos, se utilizó aceleración por hardware mediante una unidad de procesamiento gráfico (GPU) NVIDIA T4. Una vez definido el marco experimental y la infraestructura computacional, procedemos a detallar y discutir la evidencia empírica obtenida.

4. Resultados y Discusión

Tras haber formalizado el marco metodológico y definido la arquitectura de la red neuronal, este capítulo se dedica a la exposición y análisis crítico de la evidencia empírica. Lejos

de limitarnos a reportar métricas de desempeño aisladas, nuestra discusión busca establecer un vínculo causal entre las propiedades topológicas de los datos generados por la simulación (el *input*) y la capacidad de discriminación lograda por el modelo (el *output*). A continuación, desglosamos los resultados comenzando por la caracterización estadística de los regímenes regulatorios, para luego evaluar la eficacia del clasificador y finalizar con una interpretación profunda del espacio latente aprendido, confrontando las expectativas teóricas con la realidad observada en los datos sintéticos.

4.1. Caracterización Topológica de los Regímenes (Análisis del Input)

El análisis se ha realizado sobre un corpus total de 3,000 grafos simulados (1,000 por escenario), abarcando un total de 180,000 instancias de nodos bancarios. Antes de evaluar la capacidad de aprendizaje de la red, es fundamental comprender la naturaleza física de estos datos, ya que ningún modelo puede extraer patrones de donde no existen.

El primer hallazgo estructural relevante proviene del cálculo del diámetro medio de la Componente Conexa Más Grande (LCC), el cual arrojó un valor de 6.30 saltos. Este dato empírico valida *a posteriori* nuestra decisión de diseño arquitectónico: al fijar la profundidad de la GCN en 5 capas, garantizamos que el campo receptivo de cada neurona cubra aproximadamente el radio efectivo de la red, permitiendo la integración de información global sin caer en la redundancia excesiva.

Sin embargo, el análisis de las distribuciones de centralidad (**Figura 4**) revela la primera limitación intrínseca de la simulación. Al observar la *Betweenness Centrality*, notamos que el Impuesto al Riesgo Sistémico (SRT) comprime drásticamente la cola de la distribución (máximos cercanos a 0.2 frente a 0.6 en los otros casos), lo que indica que esta regulación logra desmantelar los *hubs* o nodos sistémicos. Por el contrario, la distribución bajo la Tasa Tobin es virtualmente idéntica a la del escenario de libre mercado ("Ninguno"). Esto sugiere que la Tasa Tobin actúa como una fricción volumétrica (reduciendo quizás la cantidad de dinero transaccionado) pero falla en alterar la arquitectura de conexiones del sistema. Topológicamente, el mercado con Tasa Tobin y el mercado libre son isomorfos.

La justificación para el uso de Aprendizaje Profundo se refuerza al analizar la matriz de correlación de Spearman (**Figura 5**). Se observa una correlación baja ($\rho = 0,21$) entre el *DebtRank* (variable financiera de riesgo) y la *Betweenness Centrality* (variable estructural). Esto demuestra que el riesgo sistémico no es una simple función lineal de la posición central de un banco, sino un fenómeno emergente más complejo. La GCN tiene, por tanto, acceso a información topológica ortogonal no contenida en los balances contables.

Finalmente, el Análisis de Componentes Principales (PCA) aplicado sobre los vectores promedio de los grafos confirma la intuición visual de las distribuciones. Como se aprecia en la proyección del espacio de fases (**Figura 6**), el primer componente principal (que explica el 58.05% de la varianza) logra separar con claridad el clúster correspondiente al SRT (puntos verdes) de los demás. No obstante, los escenarios de Tasa Tobin (puntos azules) y Ninguno (cruces naranjas) presentan una superposición masiva en el espacio vectorial.

Este diagnóstico del *input* establece una cota superior teórica para el rendimiento de nuestro modelo: esperamos que la red neuronal sea altamente eficaz detectando la aplicación




Figura 4: Distribución de métricas clave por escenario. A la izquierda, el SRT elimina los valores altos de intermediación, indicando una red más descentralizada. A la derecha, el SRT reduce el DebtRank medio. Nótese la superposición casi total entre los escenarios TOBIN y NINGUNO.

del SRT, pero anticipamos una confusión significativa al intentar distinguir la Tasa Tobin del libre mercado, dado que la simulación no ha generado una huella estructural distintiva para esta política.

4.2. Desempeño del Clasificador y Análisis de Errores

Al evaluar el modelo sobre el conjunto de prueba no visto (600 grafos), obtuvimos una Exactitud Global (*Accuracy*) del 57.50 %. Si bien este rendimiento supera la línea base de aleatoriedad para un problema de tres clases (33.3 %), el desglose de las métricas revela una profunda asimetría en la capacidad del modelo para .entender"los distintos regímenes. Como se detalla en el reporte de clasificación, la red exhibe un comportamiento dicotómico: es un detector excelente para el Impuesto al Riesgo Sistémico (SRT), pero fracasa sistemáticamente en la identificación de la Tasa Tobin.

El análisis de la clase SRT (Impuesto al Riesgo Sistémico) confirma la hipótesis de que esta regulación deja una huella topológica indeleble. Con una Sensibilidad (*Recall*) del 94 % y una Precisión del 66 %, el modelo casi nunca pasa por alto un escenario donde este impuesto está activo. La red neuronal ha aprendido eficazmente a reconocer la estructura descentralizada y la ausencia de *hubs* masivos como una firma inequívoca del SRT.

Por el contrario, el desempeño en la clase TOBIN es deficiente, con una sensibilidad de apenas el 17 % y un F_1 -score de 0.25. Para comprender la naturaleza de este fallo, recurrimos a la Matriz de Confusión (**Figura 7**). Los datos son reveladores: de los 200 casos reales de Tasa Tobin, el modelo clasificó erróneamente 111 como "NINGUNO"(Mercado Libre), mientras que solo acertó en 35 ocasiones.

Esta confusión no es ruido estadístico, sino una evidencia estructural. El hecho de que la GNN (una arquitectura diseñada para extraer patrones de conectividad) sea incapaz de distinguir la Tasa Tobin del Mercado Libre (prediciendo "Ninguno"la mayoría de las veces) no debe interpretarse como una alucinación del modelo, sino como una ceguera estructural inducida. La Tasa Tobin actúa como una fricción volumétrica, gravando las transacciones y reduciendo la liquidez, pero nuestra simulación demuestra que no fuerza




Figura 5: Matriz de correlación de Spearman entre las variables financieras y las métricas topológicas de los nodos.

una reorganización de los socios comerciales.

En consecuencia, para una "mirada topológica", el mercado con Tasa Tobin es isomorfo al mercado libre. El modelo predice "Ninguno" porque, estructuralmente, es indistinguible de él. Este resultado negativo es, paradójicamente, un hallazgo valioso: sugiere que intentar regular el riesgo sistémico mediante tasas planas sobre el volumen (Tobin) es ineficaz si el objetivo es modificar la arquitectura robusta de la red financiera, mientras que el SRT logra alterar la topología de manera drástica y detectable.

4.3. Interpretabilidad y Espacio Latente (Análisis de Embeddings)

Más allá de la clasificación discreta, resulta instructivo examinar la representación interna que la red neuronal ha construido del sistema financiero. Para ello, extrajimos los vectores latentes de 16 dimensiones de la capa de *Global Mean Pooling* correspondientes al conjunto de prueba y redujimos su dimensionalidad mediante la técnica t-SNE. La proyección resultante (**Figura 8**) ofrece una radiografía visual de la "cognición" del modelo.

La visualización revela una estructura fragmentada y altamente mezclada. Si bien existen regiones del espacio (particularmente en el cuadrante izquierdo) donde los puntos




Figura 6: Proyección PCA de las 3,000 simulaciones.

correspondientes al régimen SRT (círculos azules) muestran cierta agrupación exclusiva (lo que explica la alta sensibilidad reportada anteriormente), la inmensa mayoría del mapa muestra una superposición caótica entre los escenarios de Tasa Tobin (cruces verdes) y Mercado Libre (cuadrados verde claro). No se observan fronteras de decisión claras ni clústeres compactos aislados.

Esta inspección visual se corrobora cuantitativamente con el cálculo del Coeficiente de Silueta (*Silhouette Score*), el cual arrojó un valor de 0,0980. Este indicador, cercano a cero, confirma matemáticamente que la distancia intra-clase (cuán similares son los grafos de una misma regulación) es prácticamente igual a la distancia inter-clase (cuán similares son a los de otras regulaciones). En términos de aprendizaje de variedades (*manifold learning*), esto implica que las tres distribuciones de grafos comparten el mismo soporte topológico.

La baja separabilidad en el espacio latente no debe interpretarse como una incapacidad de la arquitectura GCN para extraer características, sino como una prueba de isomorfismo regulatorio en la simulación base. La red neuronal ha comprimido fielmente la información estructural de los grafos, y el hecho de que los vectores resultantes estén superpuestos demuestra que, bajo la parametrización actual del Modelo Basado en Agentes, la aplicación de la Tasa Tobin no genera una perturbación geométrica distinguible del ruido de fondo del mercado libre. La IA no está adivinando; está informando correctamente de que, estructuralmente, no hay diferencia.




Figura 7: Matriz de Confusión sobre el conjunto de test.

4.4. Discusión General: La GCN como Herramienta de Auditoría

La integración de los resultados métricos y el análisis del espacio latente nos conduce a una conclusión que trasciende la simple evaluación de un algoritmo de clasificación. Lejos de interpretar la confusión del modelo entre la Tasa Tobin y el escenario de Mercado Libre como una deficiencia técnica de la red neuronal, proponemos una lectura diferente: la GCN ha operado como una herramienta de auditoría algorítmica imparcial, revelando las propiedades emergentes reales de la simulación más allá de las expectativas teóricas.

Nuestros hallazgos presentan una discrepancia significativa respecto a las conclusiones anticipadas por la literatura seminal en la que se basa este trabajo (Poledna et al.). Mientras que los modelos teóricos sugieren que ambas intervenciones regulatorias deberían inducir cambios estructurales mensurables para mitigar el riesgo sistémico, nuestra evidencia computacional cuenta una historia distinta. La capacidad de la red para identificar el Impuesto al Riesgo Sistémico (SRT) con un 94 % de sensibilidad confirma que este mecanismo es efectivo para forzar una reorganización topológica de la red interbancaria. Sin embargo, la invisibilidad estructural de la Tasa Tobin ante un modelo no lineal profundo sugiere que, bajo la parametrización actual, este gravamen es absorbido por el sistema sin alterar su arquitectura de conexiones.

Esto implica que el sistema financiero simulado posee una resiliencia o inelasticidad estructural ante fricciones puramente volumétricas. La Tasa Tobin reduce el flujo de capital, pero no incentiva a los bancos a cambiar de socios comerciales ni a descentralizar sus exposiciones. Si una Red Neuronal Convolutiva, capaz de detectar correlaciones complejas de quinto orden, no puede distinguir un mercado con Tasa Tobin de uno libre, es porque




Figura 8: Proyección t-SNE de los vectores latentes (embeddings) del conjunto de prueba.

la diferencia fenomenológica es despreciable.

En conclusión, este estudio demuestra la utilidad del Aprendizaje Profundo Geométrico no solo como mecanismo predictivo, sino como un filtro de validación riguroso para Modelos Basados en Agentes. La Inteligencia Artificial no ha fallado en clasificar; ha tenido éxito en demostrar que, en nuestra replicación del modelo económico, la Tasa Tobin es una medida cosmética en términos de estructura de red, mientras que el SRT es una intervención quirúrgica efectiva.

5. Conclusiones

El presente trabajo ha constituido una exploración metodológica en la intersección de la Economía de la Complejidad y el Aprendizaje Profundo Geométrico, cuyo objetivo central trascendió la mera obtención de un clasificador predictivo para investigar si las regulaciones financieras dejan una huella topológica detectable en las redes interbancarias. La validación experimental de nuestro diseño confirma, en primer lugar, que es factible traducir la dinámica continua de un Modelo Basado en Agentes a representaciones estáticas de grafos enriquecidos, permitiendo que una arquitectura GCN ajustada al diámetro efectivo de la red extraiga patrones latentes y valide esta metodología para el estudio de sistemas económicos.

Sin embargo, los resultados empíricos revelan una asimetría fundamental en el impacto de las políticas estudiadas. Mientras que el Impuesto al Riesgo Sistémico (SRT) induce una descentralización estructural inequívoca que la red neuronal detecta con una sensibilidad superior al 90 %, la Tasa Tobin se ha mostrado topológicamente indistinguible del escenario de libre mercado. Lejos de interpretar esta confusión como una deficiencia técnica del modelo, concluimos que este comportamiento evidencia un isomorfismo estructural en la simulación: bajo la parametrización actual, la Tasa Tobin actúa como una fricción volumétrica que es absorbida por el sistema sin forzar una reconfiguración de las conexiones interbancarias. Esto posiciona al Aprendizaje Profundo no solo como una herramienta de clasificación, sino como un mecanismo de auditoría algorítmica capaz de verificar si los modelos teóricos generan realmente las propiedades emergentes que predicen.

A la luz de estos hallazgos, las líneas futuras de investigación deben orientarse a superar las limitaciones de la aproximación estática. Resulta imperativo explorar el uso de Redes Neuronales Temporales (como TGN o LSTM sobre grafos) para capturar dinámicas transitorias que podrían diferenciar a la Tasa Tobin por su evolución temporal más que por su estructura final. Asimismo, la resistencia estructural observada sugiere la necesidad de recalibrar el Modelo Basado en Agentes, introduciendo una mayor sensibilidad a los costes de transacción que fuerce a los agentes a alterar sus socios comerciales. Finalmente, la implementación de técnicas de explicabilidad (*Explainable AI*) permitiría identificar los subgrafos específicos que motivan las decisiones de la red, cerrando el ciclo entre la detección de patrones computacionales y la teoría económica subyacente.

Referencias

- [1] Pedro Almagro Blanco. Algoritmo de retropropagación. Universidad de Sevilla, 2024. Tema 4.
- [2] Pedro Almagro Blanco. Relational learning with neural encoders. CCIA - Universidad de Sevilla, 2024. Tema 4.
- [3] Pedro Almagro Blanco. Relational machine learning: Aprendiendo a partir de grafos. Universidad de Sevilla, 2024. Tema 3.
- [4] Dpto. de Ciencias de la Computación e Inteligencia Artificial. Aprendizaje automático. Universidad de Sevilla, 2024. Tema 3.
- [5] Dpto. de Ciencias de la Computación e Inteligencia Artificial. Introducción a los sistemas complejos. Apuntes de la asignatura Teoría de Sistemas Complejos y Datos (TSCD), Universidad de Sevilla, 2024. Tema 1.
- [6] Dpto. de Ciencias de la Computación e Inteligencia Artificial. Redes complejas. Apuntes de la asignatura Teoría de Sistemas Complejos y Datos (TSCD), Universidad de Sevilla, 2024. Tema 1.
- [7] Jure Leskovec. Graph neural networks. CS224W: Machine Learning with Graphs, Stanford University, 2018. Tema 5.
- [8] Sebastian Poledna and Stefan Thurner. Elimination of systemic risk in financial networks by means of a systemic risk transaction tax. *Quantitative Finance*, 16(10):1599–1612, 2016.